МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)» (МАИ)

Институт №8 «Информационные технологии и прикладная математика»

Кафедра 811

Лабораторная Работа №2

по курсу “Нейросетевые технологии искусственного интеллекта”

Тема: Линейная нейронная сеть. Правило обучения Уидроу-Хоффа

Студент: Дюсекеев А. Е.

Группа: М8О-101М-21

Преподаватель: Леонов С. С.

Оценка:

Москва, 2021

Цель работы:

Исследование свойств линейной нейронной сети и алгоритмов ее обучения, применение сети в задачах аппроксимации и фильтрации.

Основные этапы работы:

1. Использовать линейную нейронную сеть с задержками для аппроксимации функции. В качестве метода обучения использовать адаптацию.
2. Использовать линейную нейронную сеть с задержками для аппроксимации функции и выполнения многошагового прогноза.
3. Использовать линейную нейронную сеть в качестве адаптивного фильтра для подавления помех. Для настройки весовых коэффициентов использовать метод наименьших квадратов.

Оборудование: Intel Core i5-6200U

Программное обеспечение: MATLAB 9.2 R2017a

Сценарий выполнения работы:

Номер варианта: 2N, где N - номер студента по действующему списку. N = 5

Вариант №10:

$$x = \sin(-2t^2 + 7t) - \frac{1}{2}\sin(t), \quad t \in [0, 4.5],\ h = 0.025$$
$$x = \sin(t^2 - 6t + 3), \quad t \in [0, 6],\ h = 0.025$$

$$y = \frac{1}{3}\sin(t^2 - 6t - \frac{\pi}{6})$$

- *Часть 1. Задана временная последовательность* $x(n)$. *Построить и обучить линейную сеть с задержками, которая будет выполнять одношаговый прогноз для первой функции из варианта задания:*

  $\hat{x}(n+1) = \sum_{i=1}^{D} \omega_i x(n-i+1) + b$, *где D задает глубину погружения временного ряда (delays),* $\{\omega_w, b\}$ *— весовые коэффициенты.*

1.1 Строим обучающее множество: в качестве входного множества используем значения первого входного сигнала на заданном интервале; преобразовываем входное множество к последовательности входных образцов с помощью функции con2seq; эталонные выходы сети формируем из входной последовательности, чтобы сеть выполняла одношаговый прогноз. На рис. 1 представлен график входного сигнала.

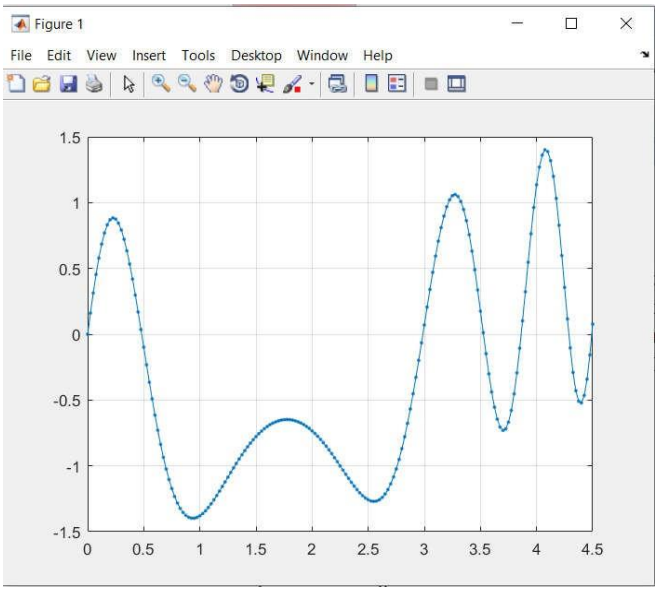

Рисунок 1. График функции

1.2 Создаем сеть с помощью функции newlin. Задаем задержки от 1 до D = 5 . Задаем скорость обучения равной 0.01. На рис. 2 отображена структура сети с помощью функции (display).

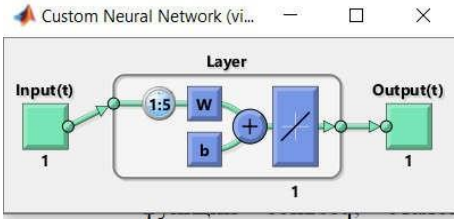

Рисунок 2. Структура сети

1.3 Инициализируем сеть случайными значениями.

1.4 Выполняем адаптацию с числом циклов равным 50. Величину ошибки обучения с помощью sqrt(mse) можно увидеть ниже. В функцию адаптации необходимо отдельно передаем первые 5 элементов входной последовательности для инициализации задержек (входной параметр Pi). В дальнейшем использовать входную и выходную последовательности,

```
M1 =  0.8515
```

начиная с 6 элемента.

1.5 На рис. 3,а представлен график эталонного значения, а на рис. 3,б представлен график предсказанный сетью. Величина ошибки обучения:

M2 = 0.2679

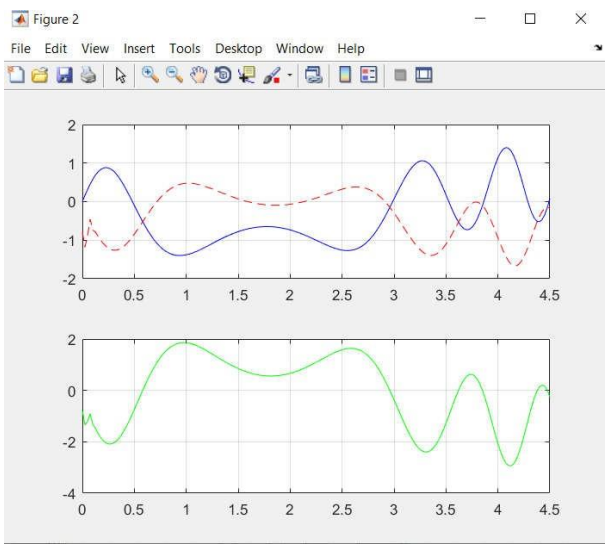

Рис 3,а

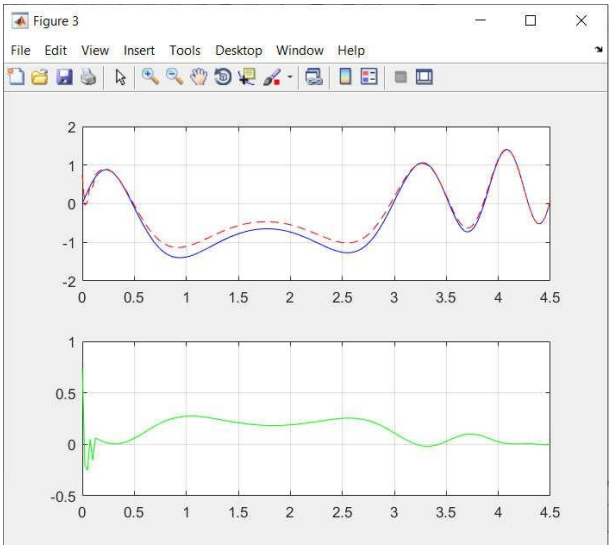

Рис 3,б

Рисунок 3. Результат работы

Листинг программы:

```
clear all;
x = @ (t) sin(-2*t.^2 + 7*t)-0.5*sin(t);
t1 = 0:0.025:4.5;
P=x(t1);
plot(t1,P,'.-'); grid;
for i=1:5
    Pi(i)=P(i);
end;
for i=1:size(P,2)-5
    PM(i)=P(i+5);
end;
net=newlin([0,5],1,[1 2 3 4 5],0.2);
display(net);
view(net);
net.inputweights{1,1}.initFcn='rands';
net.biases{1}.initFcn='rands';
net=init(net);
IW=net.IW{1,1}
b=net.b{1}
M1=sqrt(mse(PM-net(PM)))
Pi=con2seq(Pi);
PM=con2seq(PM);
P=con2seq(P);
```

```
Y=sim(net,P,Pi);
Y = seq2con(Y); Y=Y{1};
P = seq2con(P); P=P{1};
E = Y - P;
figure;
subplot(211)
plot(t1,P,'b',t1,Y,'r--'); grid;
subplot(212)
plot(t1,E,'g'); grid;
net.adaptParam.passes = 500;
[net]=adapt(net,PM,PM,Pi);
t2=0:0.025:4.5;
P=x(t2);
P=con2seq(P);
Y=sim(net,P,Pi);
Y = seq2con(Y); Y=Y{1};
P = seq2con(P); P=P{1};
E = Y - P;
M2=sqrt(mse(Y-P))
figure;
subplot(211)
plot(t2,P,'b',t2,Y,'r--'); grid;
subplot(212)
plot(t2,E,'g'); grid;
```

- *<u>Часть 2.</u> Для временной последовательности из задания 1 обучить линейную сеть с задержками (линейный адаптивный фильтр) и выполнить многошаговый прогноз.*

2.1 Строим обучающее множество: в качестве входного множества используем значения первого входного сигнала на заданном интервале; преобразовываем входное множество к последовательности входных образцов с помощью функции con2seq; эталонные выходы сети формируем из входной последовательности, чтобы сеть выполняла одношаговый прогноз.

2.2 Создаем сеть с помощью функции newlin. Задаем задержки от 1 до D = 3. Задаем скорость обучения с помощью функции maxlinlr(cell2mat(P),'bias').

```
lr=maxlinlr(P,'bias')=0.0044
```

Значение maxlinlr можно увидеть ниже.

2.3 Инициализируем сеть случайными значениями.

2.4 Задаем параметры обучения: число эпох обучения (net.trainParam.epochs) равным 600, предельное значение критерия обучения (net.trainParam.goal) равным 10E−6. Также проинициализируем задержки Pi. Выполняем обучение сети с помощью функции train. На рис. 4,а продемонстрировано окно Neural Network Training, на рис. 4.б представлен график сходимости значения ошибки.

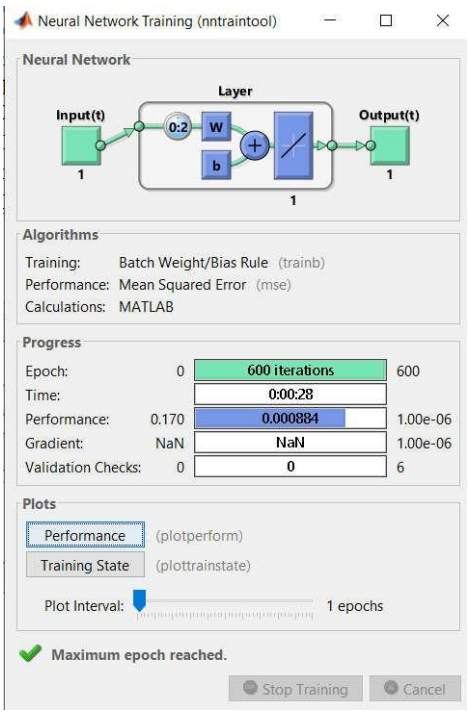

Рис 4,а

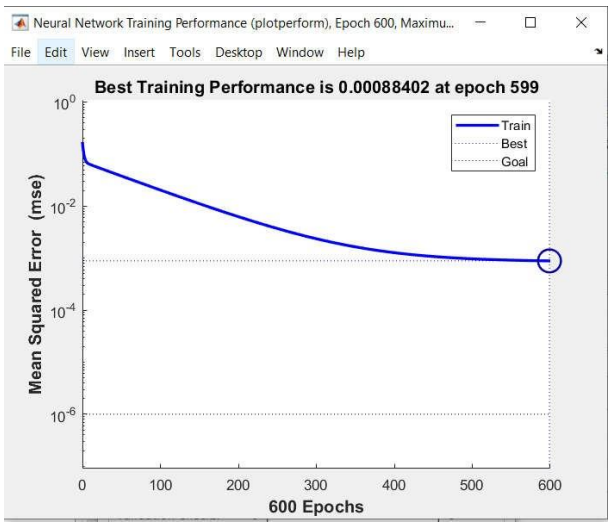

Рис 4,б

Рисунок 4. Результат работы функции train

2.5 Отобразим на графике эталонные значения и предсказанные сетью, а также ошибку обучения. На рис. 5,а можно увидеть график эталонного значения, а на рис. 5,б можно увидеть график, предсказанный сетью.

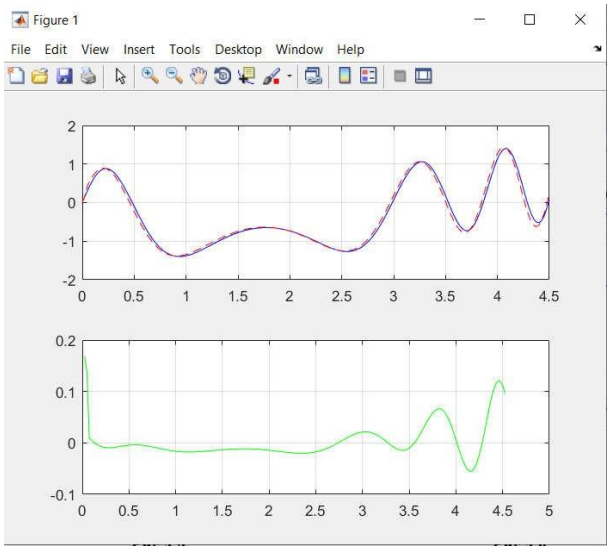

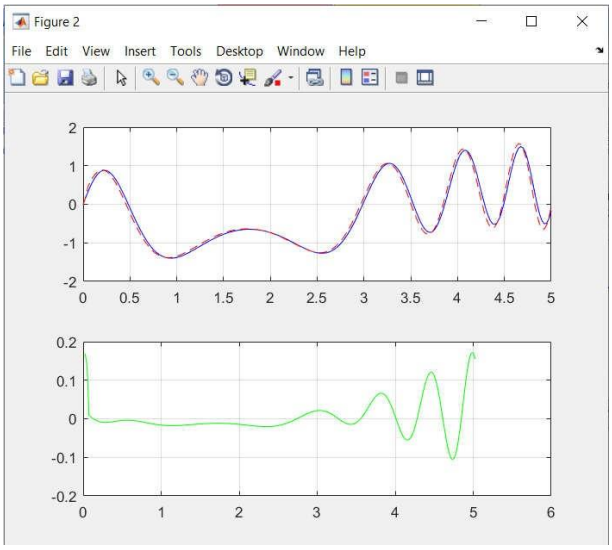

Рис 5,а **Рис 5,б**

Рисунок 5. Результат работы предсказания функции train

2.6 Сформируем набор данных для выполнения прогноза: продлим временную последовательность с заданным шагом на 10 отсчетов. Используем полученный набор данных для выполнения прогноза: рассчитаем выход сети (sim) для полученного набора. Сравним выход сети с соответствующим куском исходной временной последовательности. Отобразим на графике эталонные значения и предсказанные сетью, а также ошибку обучения. На рис. 6,а можно увидеть график эталонного значения, а на рис. 6,б можно

M3 = 0.2962

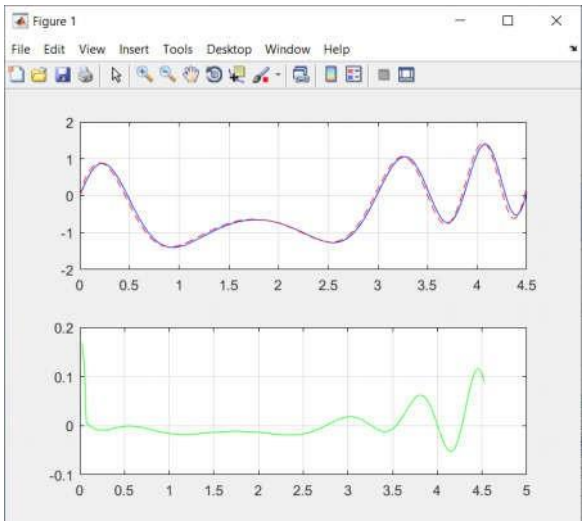

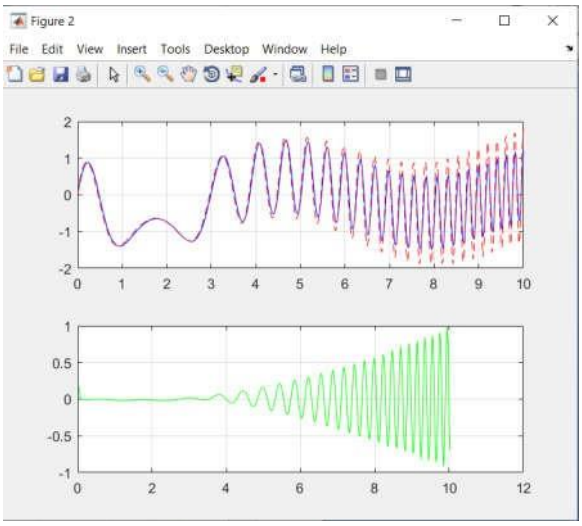

увидеть график, предсказанный сетью. Величина ошибки указана ниже:

Рис 6,а **Рис 6,б**

Рисунок 6. Результат работы предсказания функции train

Листинг программы:

```
clear all;
x = @ (t) sin(-2*t.^2 + 7*t)-0.5*sin(t);
t1 = 0:0.025:4.5;
P=x(t1);
% plot(t1,P,'.-'); grid;
for i=1:2
    Pi(i)=P(i);
end;
for i=1:size(P,2)-3
    PM(i)=P(i+2);
end;
for i=1:size(P,2)-3
    PM1(i)=P(i+3);
end;
lr=maxlinlr(P,'bias');
net=newlin([-1,1],[-1,1],[0 1 2],0.002);
%  view(net);
net.inputweights{1,1}.initFcn='rands';
net.biases{1}.initFcn='rands';
net=init(net);
IW=net.IW{1,1}
b=net.b{1}
M1=sqrt(mse(PM-net(PM)))
Pi=con2seq(Pi);
PM=con2seq(PM);
PM1=con2seq(PM1);
P=con2seq(P);
net.trainParam.goal=1E-6;
net.trainParam.epochs=600;
net=train(net,PM,PM1,Pi);
Y=net(P);
Y = seq2con(Y); Y=Y{1};
PM = seq2con(PM); PM=PM{1};
P = seq2con(P); P=P{1};
t3=0.025:0.025:4.525;
X=x(t3);
E = X - Y;
M2=sqrt(mse(Y-X));
figure;
subplot(211)
plot(t1,P,'b',t1,Y,'r--'); grid;
subplot(212)
```

```
plot(t3,E,'g'); grid;
t4=0:0.025:10;
P1=x(t4);
P2=con2seq(P1);
Y1=sim(net,P2);

Y1 = seq2con(Y1); Y1 = Y1{1};
t5=0.025:0.025:10.025;
X1=x(t5);
E1=X1-Y1;
M3=sqrt(mse(Y1-X1))
figure;
subplot(211)
plot(t4,P1,'b',t4,Y1,'r--'); grid;
subplot(212)
plot(t5,E1,'g'); grid;
```

- *Часть 3.* Построить и обучить линейную сеть, которая является адаптивным линейным фильтром. Задачей фильтра является моделирование источника шума, чтобы в последующем удалить помехи из полезного сигнала. Фильтр должен аппроксимировать отображение: $\hat{x}(n+1) = \sum_{i=1}^{D} \omega_i x(n-i+1) + b$

Вместо задержек использовать погружение временного ряда.

3.1 Построим обучающее множество: в качестве входного множества используем значения второго входного сигнала на заданном интервале; эталонными выходами сети являются значения второй эталонной функции на заданном интервале. Эталонный выходной сигнал соответствует входному сигналу, измененному по амплитуде и смещенному по фазе, поэтому диапазон значений и шаг для сигналов совпадают. На рис. 7 представлен график входного сигнала.

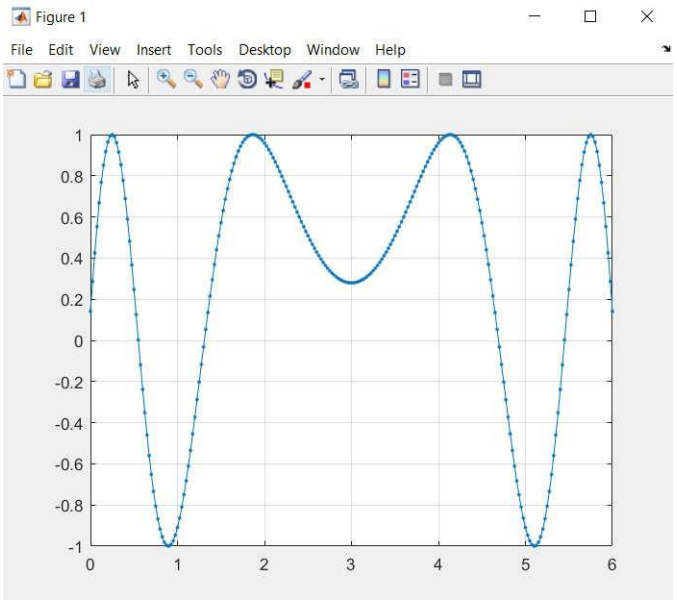

Рисунок 7. График функции

3.2 Создаем сеть с помощью функции newlind.

3.3 Рассчитаем выход сети (sim) для обучающего множества. Сравним выход сети с эталонным множеством. Отобразим на графике эталонные значения и предсказанные сетью, а также ошибку обучения. На рис. 8 можно увидеть результат работы фильтра. Величину ошибки обучения можно увидеть ниже:

MЗ = 0.0075

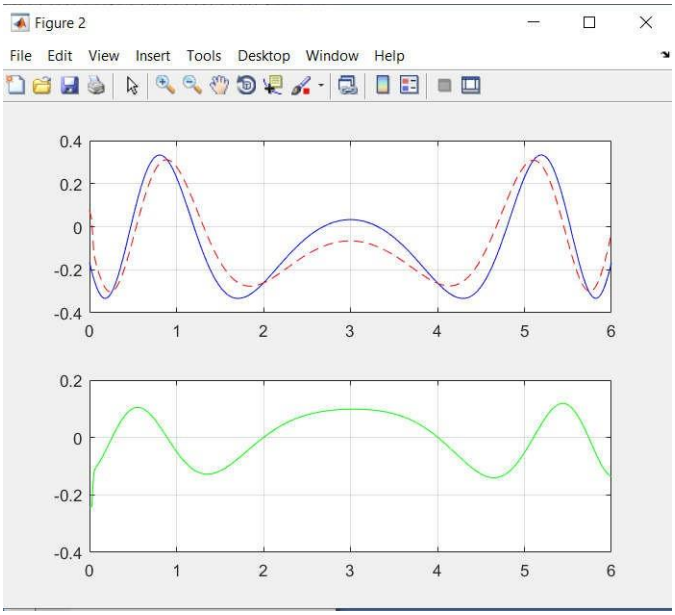

Рисунок 8. Результат работы фильтра

Среднее квадратическая ошибка и средняя ошибка представлена ниже:

```
Command Window

M3 =

    0.0075

>> mean(T-Y)

ans =

   6.6798e-18

>> std(T-Y)

ans =

    0.0866

fx >>
```

Листинг программы:

```
clear all;

%3.1 Построение обучающего множества

%Входное множество

x = @ (t) sin(t.^2 - 6*t + 3);

%Эталонный выход

y = @ (t) (1/3)*sin(t.^2 - 6*t -
pi/6); t1=0:0.025:6;

P=x(t1);
```

```
plot(t1,P,'.-'); grid;

%3.2 Расширение входного множества
P1=zeros(4,size(P,1));

for i=1:3

    P2(i)=0;

end;

for i=1:size(P,2)
    P2(i+3)=P(i);

end;

for i=1:4

    P3(i,1:size(P,2))=P2(i:size(P,2)+i-1);

end;
T=y(t
1);

T=con2seq(T);
P=con2seq(P3);

%3.3
Создаем
сеть
net=newlin
d(P,T);
Y=net(P);

Y = seq2con(Y);

Y = Y{1};

T = seq2con(T);

T = T{1};

M3=mse(T-Y)

figure;
subplot(211)

plot(t1,T,'b',t1,Y,'r--'); grid;
subplot(212)

plot(t1,T-Y,'g'); grid;
```

Вывод: В данной лабораторной работе исследованы свойства линейной нейронной сети и алгоритмов ее обучения, применение сети в задачах аппроксимации и фильтрации. В ходе лабораторной

работы мне удалось выделить некоторые наблюдения в работе сети, а именно недостатки: данный способ решения позволяет предсказывать недалекое будущее. Во 2-ом этапе лабораторной работы можно увидеть, что при увеличении времени (например, до 10) ошибка точности увеличивается; достоинства: линейная нейроная сеть с правилом Уидроу-Хоффа позволяет использовать сеть для аппроксимации функции, выполнения прогноза и в качестве адаптивного фильтра для фильтрации помех. Стоит отметить метод *newlind*. Данный метод точнее решает задачу, оценка точности схожа с аналитическим решением.